

이화여자대학교 데이터사이언스학과

공연장 좌석 점유 예측 기반 가격 세분화 정책 제안

데이터 분석 보고서



제출자 : 2392032 정지영

팀원 : 2392025 임령아 2392032 정지영

지도교수 : 김상엽

제출일 : 2026년 6월 19일

목차

1. 서론	3
1.1. 연구 배경	3
1.1.1. 공연 산업 현황	3
1.1.2. 국내 뮤지컬 산업의 가격 경직성 문제	4
1.2. 연구 목표	5
1.2.1. 연구의 궁극적 목표	5
1.2.2. 세부 연구 목표	6
1.2.3. 연구 범위 및 의의	6
2. 데이터	8
2.1. 데이터 구축	8
2.2. 데이터 탐색	9
2.2.1. 좌석 등급별 특성	9
2.2.2. 캐스팅과 캐스팅 파워(인스타그램 팔로워 수)	10
2.2.3. 결측치와 대응 방법	12
3. 방법론	14
3.1. 피쳐 엔지니어링	14
3.1.1. 좌석 매핑	14
3.1.2. 텍스트 리뷰 기반 키워드 가중 좌석 평점 생성	14
3.1.3. 좌석과 무대 간 공간 정보 반영 변수 생성	15
3.2. 분석용 데이터 프레임 생성	16
3.3. 모델링	17
3.3.1. 모델 성능 비교	18
3.3.2. 최종 모델 선정 및 추가 최적화	18
3.3.3. 확률 예측 품질 평가	18
3.4. 정책 시뮬레이션 설계	19
4. 결과	21
4.1. 최종 모델 선정 및 모델 관찰	21
4.1.1. 최종 모델 선정	21
4.1.2. 추가 튜닝 및 모델 성능 관찰	21

4.2. 확률 예측 품질 평가.....	25
4.3. 정책 시뮬레이션 결과.....	27
4.3.1. 회차별 가격 세분화 결과	27
4.3.2. 회차별 KPI 비교	28
4.3.3. 전체 회차 성과 비교	28
5. 결론	29
5.1. 결론 및 제언	29
5.2. 프로젝트의 한계 및 향후 과제	29
참고문헌	31
부록	33

1. 서론

1.1. 연구 배경

1.1.1. 공연 산업 현황

최근 국내 공연예술 산업은 지속적인 성장세를 보이고 있다. 공연예술통합전산망(KOPIS)의 「2025 공연예술조사」에 따르면, 2025년 기준 국내 공연은 총 23,608건, 136,579회 개최되었으며, 티켓 예매 건수는 약 2,478만 매, 티켓 판매액은 약 1조 7,326억 원에 달하였다. 이는 전년 대비 티켓 예매 수는 약 241만 매, 티켓 판매액은 약 2,738억 원 증가한 수치로, 공연 산업이 문화산업의 중요한 축으로 자리매김하고 있음을 보여준다.

현재 국내 공연 시장 중에서도 뮤지컬이 가장 높은 시장성과 성장성을 보이고 있다. 2025년 티켓판매액 상위 20개 공연 중 10개의 공연이 뮤지컬 공연(《알라딘》, 《지킬 앤 하이드》, 《위키드》 내한공연, 《팬텀》, 《웃는 남자》, 《멤피스》, 《미세스 다웃파이어》, 《맘마미아!》, 《명성황후》)으로 나타났다. 또한 2025년 뮤지컬 장르는 공연 건수, 공연 회차, 티켓 예매 수, 티켓 판매액이 모두 전년 대비 증가하였으며, 티켓 예매 수는 약 70만 매, 티켓 판매액은 약 336억 원 증가하였다.


장르	공연명	공연기간	공연시설/공연장	지역	좌석수
대중음악 (내한)	콜드플레이 내한공연 [고양]	2025-04-16 ~ 2025-04-25	고양종합운동장 주경기장	경기도	43,000석
뮤지컬 (라이선스)	알라딘	2024-11-17 ~ 2025-06-22	사롯데씨어터	서울특별시	1,230석
서커스/마술	태양의서커스, 쿠자 [서울]	2025-10-11 ~ 2025-12-28	잠실종합운동장 빅탑	서울특별시	2,400석
뮤지컬 (라이선스)	지킬앤하이드	2024-11-29 ~ 2025-05-18	블루스퀘어 신한카드홀 (구. 인터파크홀)	서울특별시	1,766석
뮤지컬 (내한)	위키드 내한 공연	2025-07-12 ~ 2025-10-26	블루스퀘어 신한카드홀 (구. 인터파크홀)	서울특별시	1,766석
뮤지컬 (라이선스)	팬텀	2025-05-31 ~ 2025-08-11	세종문화회관 세종대극장	서울특별시	3,022석
뮤지컬 (라이선스)	알라딘 [부산]	2025-07-11 ~ 2025-09-28	드림씨어터 [부산]	부산광역시	1,727석
대중음악 (아이돌)	DAY6 3RD WORLD TOUR: FOREVER YOUNG FINALE [서울]	2025-05-09 ~ 2025-05-18	올림픽공원 KSPO DOME(체조경기장)	서울특별시	15,000석
뮤지컬 (창작)	웃는 남자	2025-01-09 ~ 2025-03-09	예술의전당 [서울] 오페라극장	서울특별시	2,283석
대중음악 (아이돌)	BLACKPINK WORLD TOUR [고양]	2025-07-05 ~ 2025-07-06	고양종합운동장 주경기장	경기도	43,000석
대중음악 (브랜딩공연)	김동률 콘서트·산책	2025-11-08 ~ 2025-11-16	올림픽공원 KSPO DOME(체조경기장)	서울특별시	15,000석
대중음악 (브랜딩공연)	싸이홈백쇼: SUMMERSWAG [과천]	2025-07-18 ~ 2025-07-20	과천 서울대공원 주차광장	경기도	0석
뮤지컬 (창작)	멤피스	2025-06-17 ~ 2025-09-21	충무아트센터 대극장	서울특별시	1,250석
대중음악 (내한)	오아시스 내한공연 [고양]	2025-10-21 ~ 2025-10-21	고양종합운동장 주경기장	경기도	43,000석
뮤지컬 (라이선스)	미세스 다웃파이어 [서울]	2025-09-27 ~ 2025-12-07	사롯데씨어터	서울특별시	1,230석
대중음악 (브랜딩공연)	임영웅 콘서트: IM HERO TOUR [서울]	2025-11-21 ~ 2025-11-30	올림픽공원 KSPO DOME(체조경기장)	서울특별시	15,000석
대중음악 (브랜딩공연)	싸이홈백쇼: SUMMERSWAG [부산]	2025-08-15 ~ 2025-08-16	부산아시아드 보조경기장	부산광역시	4,549석
뮤지컬 (라이선스)	맘마미아! [서울]	2025-07-26 ~ 2025-10-25	LGA아트센터 서울 LG SIGNATURE 홀	서울특별시	1,335석
뮤지컬 (창작)	명성황후	2025-01-21 ~ 2025-03-30	세종문화회관 세종대극장	서울특별시	3,022석
서커스/마술	태양의서커스, 쿠자 [부산]	2025-08-21 ~ 2025-09-28	신세계 문화홀 [센텀시티] 빅탑	부산광역시	0석

[그림 1] 2025 공연시장 티켓판매액 상위20개 공연 목록 (출처: KOPIS)

그러나 이러한 양적 성장에도 불구하고, 공연 1회당 평균 티켓 판매액은 전년 대비 약 6.5% 티켓 1매당 평균 판매액은 약 1.6% 감소한 것으로 나타났다. 이는 시장 규모는 확대되고 있지만 개별 공연의 수익성은 오히려 감소하고 있으며 변화하는 수요를 충분히 반영하지 못하고 있음을 시사한다. 수익성 하락은 제작비 상승, 편성 증가 등 여러 원인이 있어, 여러 원인 중 하나로 가격 책정 방식의 경직성을 들 수 있다. 따라서 수요 변화에 대응하는 정교한 가격 전략의 필요성이 제기된다.

1.1.2 국내 뮤지컬 산업의 가격 경직성 문제


개별 공연의 수익성의 원인을 티켓 판매 방법에서 찾아보면, 국내 공연장의 좌석 가격 책정 방식은 정적인(Fixed Pricing) 구조를 유지하고 있는 것에서 그 이유를 찾을 수 있다. 국내 대형 창작·라이선스 뮤지컬 대부분은 좌석을 VIP·R·S 등 3~5개 등급으로만 구분하며, 동일 등급 내에서는 실제 시야나 음향 환경의 차이를 충분히 반영하지 못한다. 예를 들어, 동일한 VIP석이라도 무대 중앙과 가까운 좌석과 사이드 좌석은 관람 경험에 상당한 차이가 존재하지만 동일한 가격이 적용되는 경우가 일반적이다.



[그림 2] 동일 등급 두 좌석 간 시야 차이 (출처: 인터파크 NOL 좌석미리보기)

이러한 가격 경직성은 관객과 공연 기획사 모두에게 비효율을 초래한다. 관객은 실제 좌석 가치와 무관하게 동일한 가격을 지불해야 하며, 공연 기획사는 선호도가 낮은 좌석의 미판매로 인해 잠재적인 수익을 확보하지 못하는 문제가 발생한다. 특히 공연 티켓은 공연이 시작되면 재고 가치가 완전히 소멸되는 대표적인 시간 제약성(Time-sensitive) 상품으로, 용량이 제한된 서비스의 수익경영(Revenue Management) 관점에서 접근할 필요가 있다 (Kimes, 1989; Gallego&van Ryzin, 1994). 실제로 브로드웨이에서는 좌석위치·수요·예매 시점을 반영한 가격 세분화가 수익을 유의하게 증대시킨다는 점이 실증되었다. (Leslie, 2004). 해외 공연 산업에서는 이러한 특성을 반영하여 Dynamic Pricing 전략을 적극적으로 도입하고 있다. 브로드웨이의 대표적인 뮤지컬들은 좌석 위치와 공연 수요, 예매 시점 등을 종합적으로

고려하여 동일 구역 내에서도 세분화된 가격 정책을 운영하고 있으며, 이를 통해 좌석 점유율과 수익을 동시에 최적화하고 있다. 반면 국내 공연 산업에서는 좌석별 판매 이력, 관람객 리뷰, 캐스팅 정보 등 다양한 데이터를 활용한 가격 의사결정 체계가 아직 충분히 구축되어 있지 않다.



[그림 3] 브로드웨이 뮤지컬 *Wicked*의 7등급 가격 정책 사례 (출처: BroadwayDirect)

특히 특정 좌석의 판매 여부는 단순한 좌석 위치뿐 아니라 캐스팅 라인업, 공연 일정, 예매 시점, 관람객의 실제 리뷰와 같은 다양한 요인의 영향을 동시에 받는다(주예린 외 3인, 2023). 즉, 좌석 단위의 수요는 여러 요인이 복합적으로 작용한 결과이므로, 소수의 좌석 등급에 기반한 기존의 정적 가격 체계만으로는 이를 충분히 설명하기 어렵다. 따라서 이러한 다차원적인 데이터를 통합하여 좌석 단위의 수요를 예측하고, 이를 기반으로 보다 합리적인 가격 정책을 제안할 수 있는 데이터 기반 의사결정 시스템의 필요성이 점차 커지고 있다.

1.2. 연구 목표

1.2.1 연구의 궁극적 목표

본 연구의 궁극적인 목표는 공연장의 좌석 단위 판매 데이터를 기반으로 좌석 점유 여부를 예측하는 모델을 구축하고, 그 예측 결과를 활용해 데이터 기반의 가격 세분화 정책을

제안하는 데 있다. 이를 통해 좌석별 수요를 정량적으로 추정하고, 이를 공연장의 수익 최적화와 합리적인 가격 정책 수립을 위한 의사결정 지원 도구로 발전시키고자 한다.

1.2.2 세부 연구 목표

앞선 목표를 달성하기 위해 다음의 세 가지 세부 연구 목표를 설정하였다.

첫째, 좌석 위치, 캐스팅, 공연 일정, 관람 리뷰 등 다양한 요인을 활용하여 좌석별 판매 여부와 판매 확률을 예측하는 머신러닝 모델을 구축한다.

둘째, 모델 해석을 통해 좌석 판매에 영향을 미치는 주요 요인을 식별하고, 각 요인이 판매 확률에 미치는 영향을 분석한다.

셋째, 예측된 판매 확률을 바탕으로 다양한 가격 시나리오를 시뮬레이션하고, 기존의 고정 가격 정책 대비 수익성과 좌석 활용도를 개선할 수 있는 가격 세분화 정책을 제안한다.

1.2.3 연구 범위 및 의의

분석 대상으로 뮤지컬 《렘피카》를 선정하였으며, 그 이유는 다음과 같다. 먼저, 《렘피카》는 947석 규모의 코엑스 신한카드 아티움에서 공연된 작품으로, 2025년 국내 뮤지컬 시장 공연 회차에서 전체의 약 32.7%로 가장 큰 비중을 차지한 500~1,000석 중극장(이영빈, 2026)을 대표한다. 둘째, 동일 작품 안에서도 회차별 캐스팅이 달라져, 좌석 위치뿐 아니라 배우 조합에 따른 수요 변화를 함께 관찰할 수 있다. 셋째, 인터파크 NOL에서 단독으로 판매되어 판매처에 따른 가격 변동의 영향을 통제할 수 있다. 이러한 점에서 《렘피카》는 좌석별 판매 여부 예측 문제를 다루기에 적합한 사례로 판단하였다.

구분	2025년		2024년		2023년		2022년		2021년	
	공연건수	공연회차	공연건수	공연회차	공연건수	공연회차	공연건수	공연회차	공연건수	공연회차
공연시장 전체	3,402	46,072	2,986	40,194	3,191	38,950	2,756	32,175	1,565	20,777
1,000석 이상	548	5,422	512	5,291	640	6,135	554	5,600	304	4,248
500석~1,000석 미만	1,112	8,533	971	7,393	1,036	7,726	953	7,306	509	3,886
300석~500석 미만	870	9,950	750	10,022	783	9,298	624	6,900	321	4,735
1석~300석 미만	768	19,701	667	16,225	677	15,256	605	11,925	421	7,769
0석(좌석미상)	104	2,466	86	1,263	55	535	20	444	10	139

[그림 4] 2021~2025 뮤지컬 시설 규모별 공연건수/공연회차 현황 (출처: KOPIS)

분석에서는 총 26개 회차의 좌석 판매 데이터를 활용하였으며, 최종 분석 단위는 '좌석 × 공연 회차'로 정의한다. 각 단위에 대해 해당 좌석의 최종 판매 확률을 예측하고, 실제 운영 중인 가격 체계를 기준으로 가격 세분화 시나리오를 시뮬레이션하여 그 효과를 검증한다.


이 연구의 의의는 다음과 같다. 학술적으로는 그간 좌석 등급 단위에서 논의되던 공연 가격 문제를 좌석 단위의 미시적 수요 예측으로 확장하고, 이를 가격 정책 시뮬레이션과 직접 연결했다는 점에서 차별성을 가진다. 방법론적으로는 좌석 위치와 가격, 캐스팅 정보와 배우 영향력과 같은 정형 데이터에 더해 관람 리뷰 텍스트(키워드 가중 좌석 평점)의 비정형 데이터를 통합하여 좌석 가치를 다차원적으로 정량화하였다. 실무적으로는 공연 기획사가 고정 가격 체계에서 발생하는 기회손실을 정량적으로 진단하고, 좌석별 수요에 근거해 가격을 조정할 수 있는 의사결정의 근거를 제공한다. 다만 정책 효과는 가상의 시뮬레이션 환경에서 검증되므로, 그 결과는 가격 변화가 판매를 직접 유발한다는 인과관계의 입증이 아니라 데이터 기반 가격 의사결정의 가능성을 탐색하는 데 초점이 있음을 밝혀 둔다.

2. 데이터

2.1. 데이터 구축

본 연구에서는 좌석 판매 여부를 예측하기 위해 공연 정보, 좌석 정보, 관람 후기, 캐스팅 정보를 서로 다른 데이터 소스로부터 수집하였다.

좌석 판매 현황과 가격 정보는 실제 예매가 이뤄지는 '인터파크 NOL'에서 좌석 판매 여부 스냅샷을 크롤링하여 수집하였다. 해당 스냅샷에는 판매 화면상 좌석 위치 정보(x, y), 좌석별 판매 여부, 좌석 등급, 좌석 가격, 공연일시, 회차별 캐스팅 정보 등의 내용이 포함된다. 좌석 판매 여부는 시간에 따라 지속적으로 변하기 때문에 일정한 기준 시점에서 데이터를 수집하는 것이 중요하다. KOPIS 공연예술통합전산망 통계에 따르면, 티켓 예매는 오후 6시~9시 사이에 가장 활발하게 발생하며, 오후 9시 이후에는 예매량이 급격히 감소하는 경향을 보인다. 따라서, 5/3~5/24동안 매일 23시 30분에 크롤링을 수행하여 총 26회 공연에 대한 일별 좌석 스냅샷 데이터를 구축하였다. 각 크롤링 결과는 MongoDB에 공연 회차별 JSON 형태의 다큐먼트로 저장되었으며, 동일 좌석의 일자별 판매 상태를 추적할 수 있도록 구성하였다.



[그림 5] 시간 당 총 티켓예매수 통계 (출처: KOPIS)

좌석별 관람 품질 정보를 Seeya! 플랫폼을 크롤링하여 수집하였다. 해당 플랫폼은 실제 공연 관람객이 좌석 경험을 공유하는 플랫폼으로 좌석 리뷰 텍스트와 시야, 좌석, 조명, 음향의 4가지 측면에 대한 좌석 평점을 수집했다. 텍스트 리뷰는 이후 키워드 기반 평점 생성 과정을 통해 피쳐 엔지니어링을 진행했다.

뮤지컬은 동일 작품이라도 회차별 캐스팅에 따라 예매 수요가 달라지는 특성이 존재한다 이를 반영하기 위하여 《렘피카》 출연 배우들의 Instagram 팔로워 수를 직접 수집하였다.

2.2. 데이터 탐색

수집한 데이터를 탐색한 결과 다음과 같은 특징들을 발견하였다.

2.2.1 좌석 등급별 특성

class	판매율	가격
OP	93.7%	150,000
VIP	66.2%	150,000
R	54.8%	120,000
S	26.3%	100,000
A	52.1%	80,000
휠체어	100%	0


[표 1] 좌석 등급별 판매율 및 가격

[표1]에서처럼 좌석 등급은 판매율과 뚜렷한 관계를 보인다. 무대에 가장 가까운 OP석이 93.7%로 가장 높고, 측면과 후방에 분포한 S석이 26.3%로 가장 낮아, 좌석의 위치와 등급이 판매에 강하게 작용함을 확인할 수 있다. 다만 가격과 판매율이 단순 비례하지는 않는데, 동일 가격인 OP와 VIP의 판매율 차이나, 더 저렴한 A석이 상위 등급인 S석보다 오히려 높은 판매율을 보이는 점은 가격 외 위치 요인의 영향을 시사한다.

그러나 등급 단위 집계만으로는 판매 양상을 충분히 설명하기 어렵다. 같은 등급 내에서도 좌석의 좌우 위치와 앞뒤 위치에 따라 판매율 편차가 크게 나타났기 때문이다. 이를 확인하기 위해, 2025년 뮤지컬 유료티켓 예매율(88.0%)에 미치지 못하는 등급을 대상으로 구역과 열 단위로 추가 분할하여 판매율을 비교하였다.

먼저 좌우 위치 기준에서는 중앙(B)과 측면(A·C)의 차이가 두드러졌다. VIP석은 중앙 B구역이 84.7%인 반면 측면 A·C구역은 60% 안팎(60.9%, 62.9%)에 머물렀고, A석 역시 중앙 B구역이 70.3%로 높은 데 비해 측면은 20%대(19.7%, 22.6%)로 급감하였다. 동일 등급, 동일 가격임에도 중앙과 측면 사이에 최대 50%p 가까운 격차가 존재하는 것이다.

다음으로 앞뒤 위치 기준에서는 특정 열을 경계로 판매율이 급락하는 구간이 관찰되었다. VIP석은 15열(약 88%)에서 16열(약 39%)로, R석은 3열(약 49%)에서 4열(약 38%)로, S석은 1열(약 59%)에서 2열(약 22%)로 떨어지며, 모두 앞열과 뒷열 사이에 뚜렷한 단절이 나타났다. 이러한 결과는 현행 등급 체계가 동일 등급 내부의 가치 차이를 반영하지 못하고 있음을 보여준다. 같은 가격을 지불하더라도 중앙·앞열과 측면·뒷열의 실제 판매는 크게 달라지며, 이는 좌석을 등급보다 더 세분화된 단위에서 예측·평가할 필요가 있음을 뒷받침한다. 따라서 본 연구에서는 좌석 단위의 위치 정보를 핵심 변수로 활용하여 판매 여부를 예측하고자 한다.



[그림 6] 《렘피카》 좌석별 판매 비율

2.2.2 캐스팅과 캐스팅 파워(인스타그램 팔로워 수)

《렘피카》는 7개 역할(렘피카, 라파엘라, 마리네티, 타데우스, 수지, 남작부인, 남작)에 대해 회차마다 배우를 교체하는 멀티 캐스팅 방식으로 운영되었으며, 전체 출연 배우는 총 15명이다. 각 배우의 출연 회차와 무대 출연 비율, 인스타그램 팔로워 수, 그리고 해당 배우 출연 회차의 평균 좌석 판매율을 정리하면 [표 2]와 같다.

역할	배우	출연회차	무대비율	insta_ follower	insta_ rank	판매율(%)	판매율 rank
렘피카	박혜나	9	33.9%	18,000	7	49.4%	16
	김선영	9	33.5%	9587	10	53.7%	13
	정선아	8	32.6%	140,000	2	76.8	2
라파엘라	손승연	13	51.6%	42,000	4	51.6%	15
	린아	9	32.3%	59,000	3	57.1%	12
	차지연	4	16.1%	34,000	5	89.6%	1
마리네티	조형균	19	78.4%	26,000	6	61.9%	3
	김호영	7	21.6%	233,000	1	52.3%	14
타데우스	김민철	13	50%	1,548	13	58.4%	8
	김우형	13	50%	10,000	9	60.3%	5
수지	김혜미	18	72.6%	2,718	12	59.7%	4
	최정원	8	27.4%	17,000	8	58.5%	10
남작부인	김현숙	13	50%	nan	16	60.1%	7
	윤사봉	13	50%	8,529	11	58.5%	11
남작	김민수	13	50%	335	14	60.3%	6
	김남수	13	50%	238	15	58.4%	9

[표 2] 《렘피카》역할, 배우 별 출연 및 판매 특성

이때 판매율은 "해당 배우가 출연한 회차에서 각 좌석이 판매되었는지"의 평균값으로, 회차 단위의 전체 매진율(947석 중 판매 좌석 비중)과는 구분된다. 또한 이 값에는 좌석 등급(OP, VIP 등)과 요일·시간대의 영향이 함께 섞여 있어, 배우 단독의 효과로 해석하기 어렵다는 점에 유의해야 한다.

실제로 캐스팅에 따른 판매율 격차는 주연(렘피카, 라파엘라)에서만 두드러졌고, 조연, 단역에서는 배우가 바뀌어도 판매율이 대체로 유사하였다(58~60%대). 예컨대 라파엘라 역의 차지연(89.6%)과 손승연(51.6%)은 큰 차이를 보였으나, 이는 배우 인기만으로 보기 어렵다. 차지연은 출연 회차가 4회로 적고, 그중 100% 판매 회차가 렘피카 역 정선아와의 짝

캐스팅이었으며, 저판매 시간대(평일 수요일 오후)가 포함되지 않았다. 반면 손승연은 13회로 출연이 많아 저판매 시간대까지 폭넓게 포함되어 평균이 낮아졌다. 즉 두 배우의 격차는 출연 회차 구성, 짝 캐스팅, 공연 일정의 차이에 기인한 것으로 볼 수 있으며, 동시에 인기 배우가 상대적으로 수요가 높은 시간대에 배치되었을 가능성도 배제하기 어렵다.

인스타그램 팔로워 수 또한 판매율과 단순 비례하지 않았다. 팔로워가 가장 많은 김호영(약 23.3만, 1위)의 판매율은 52.3%로 하위권인 반면, 팔로워 5위인 차지연(약 3.4만)은 판매율 1위를 기록하였다. 이는 배우의 인지도(팔로워)가 곧바로 좌석 판매로 이어지지 않으며, 캐스팅 효과가 좌석 등급·일정 등 다른 요인과 복합적으로 작용함을 보여준다. 따라서 캐스팅과 팔로워 수는 예측 변수로 활용하되, 그 효과는 다른 요인을 통제된 모델 안에서 해석할 필요가 있다.

2.2.3 결측치와 대응 방법

수집된 데이터의 결측은 크게 세 갈래로 나타났으며, 각 결측의 발생 원인이 명확하여 원인별로 대응 방안을 달리하였다.

첫째, 좌석 리뷰 평점 계열 변수(avg_rating, visibility_kw_rating, seat_kw_rating, lighting_kw_rating, sound_kw_rating)에서 약 53~54%의 높은 결측률이 나타났다. 이는 리뷰 출처인 Seeya! 데이터에서 이용자가 텍스트 후기는 남겼으나 항목별 별점을 입력하지 않아 평점이 집계되지 않은 경우에서 비롯된다. 절반 이상의 좌석에 평점이 비어 있어 단순 삭제나 평균 대치로는 정보 손실이 크다고 판단하였다. 이에 본 연구에서는 평점 자체를 대치하는 대신, 텍스트 리뷰가 강조하는 요소(시야, 좌석, 조명, 음향)를 반영한 키워드 가중 좌석 평점을 별도로 생성하여 결측을 보완하였다. 구체적인 생성 방법은 3.1.2.에서 다룬다.

둘째, insta_남작부인 컬럼의 약 51% 결측은 해당 역할을 13개 회차에서 연기한 김현숙이 인스타그램 계정을 보유하지 않은 데서 발생하였다. 이는 데이터 수집 누락이 아니라 실제로 값이 존재하지 않는 경우이므로, 임의로 대치하지 않고 결측(NaN)으로 유지하였다. 조·단역의 팔로워 변수는 판매율에 미치는 영향이 제한적이어서 분석에 미치는 왜곡도 크지 않다.

셋째, seat_no와 rating_count에서 약 1%의 결측이 확인되었는데, 이는 모두 동일한 3,100개 행, 즉 휠체어석에서 발생한 구조적 결측이다. 인터파크 판매 페이지에서 휠체어석은 개별 좌석 번호 없이 구역 단위 라벨로만 설계되어 있어 좌석 번호와 리뷰 수가 비어 있다. 휠체어석은 무료, 전량 판매 처리되어 판매율과 가격 분석을 왜곡할 수 있으므로, 해당 분석 단계에서는 별도로 분리하여 처리하였다.

요약하면, 리뷰 평점 계열의 결측은 절반 이상으로 가장 비중이 크지만 이는 키워드 가중 평점 피처로 대체하였고, 팔로워, 휠체어석 결측은 각각 실제 부재와 구조적 설계에 따른 것으로 원인에 맞게 유지 혹은 분리하였다. 이로써 결측이 모델 학습에 미치는 영향을 최소화하였다.

3. 방법론

3.1. 피쳐 엔지니어링

3.1.1 좌석 매핑

인터파크 예매 페이지에서 좌석 판매여부 스냅샷 수집 시 좌석의 위치가 화면상의 좌표값(x, y) 형태로 제공되며, 실제 좌석 정보(층, 열, 좌석 번호)는 직접 제공되지 않는다. 따라서 본 연구에서는 인터파크 좌석 배치도 이미지를 기준으로 판매 화면의 좌표를 대응시켜 각 좌석에 대한 위치 정보를 복원하였다. 이를 통해 각 좌석에 대한 기본 위치 정보를 생성하였다.



[그림 7] 실제 등급 운영 안내에 따른 좌석 맵핑 결과

3.1.2 텍스트 리뷰 기반 키워드 가중 좌석 평점 생성

Seeya! 플랫폼은 좌석별 평균 평점(시야, 좌석 편안함, 조명, 음향)을 제공하지만, 동일한 평점이라도 실제 관람 경험은 리뷰 내용에 따라 크게 달라질 수 있다. 예를 들어, 같은 시야 평점이라도 "배우 표정이 잘 보였다.", "사이드라 고개를 계속 돌려야 했다." 와 같이 서로 다른 관람 경험이 존재할 수 있다. 따라서 본 연구에서는 리뷰 텍스트를 분석하여 각 좌석의 실제 관람 경험을 보다 정교하게 반영하는 텍스트 기반 평점 Feature를 생성하였다.

공연 리뷰는 팬덤 용어, 공연 특화 표현, 좌석 관련 은어가 많이 포함되어 있어 일반적인 감성 사전만으로는 분석이 어렵다. 이에 따라 리뷰를 시야, 좌석 편안함, 조명 및 연출, 음향의 네 가지 관점으로 구분하였다.

각 관점에 대해 수동으로 딕셔너리를 구축한 후, 리뷰를 문장 단위로 분리하여 해당 키워드가 포함된 문장을 관점 별로 분류하였다. 이후 토큰 빈도와 로그 비율 기반 점수를 이용하여 관점 별 대표 키워드를 추출하고, 이를 통해 기존 딕셔너리를 확장하였다.

리뷰에서 특정 관점이 얼마나 많이 언급되었는지를 가중치로 반영하여 기존 평점을 보정하였다. 키워드 출현 빈도를 기반으로 관점 중요도를 계산하고, 로그 변환과 Min-Max 스케일링을 적용하여 1~5 범위의 보정 점수를 생성하였다. 최종 평점은 기존 평점과 키워드 기반 점수를 아래 수식을 이용해 가중 평균하여 계산하였다.

$$S_a = \lambda \cdot R_a + (1 - \lambda) \cdot K_a$$

기호	정의
S_a	가중 평균이 적용된 점수
R_a	기존 좌석 평점
K_a	키워드 반 보정 점수
λ	0.85

[표 3] 키워드 가중치 계산 기호 별 정의

최종적으로 visibility_kw_rating, seat_kw_rating, lighting_kw_rating, sound_kw_rating 네 개의 피처를 생성하였다. 이러한 Feature는 좌석의 실제 관람 경험을 반영하는 변수로 활용되며, 좌석 판매 여부 예측과 가격 세분화 정책 수립에 사용된다.

3.1.3 좌석과 무대 간 공간 정보 반영 변수 생성

인터파크 좌석 배치도에서 제공되는 각 좌석의 좌표 정보(x, y)를 활용하여, 단순한 좌석 번호가 아닌 실제 관람 위치를 반영할 수 있는 공간적 피처를 생성하였다. 동일한 등급이라도 무대와 거리나 중앙선으로부터의 위치에 따라 관람 만족도와 판매율이 크게 달라질 수 있으므로, 이를 정량적으로 모델에 반영하고자 하였다. 무대 중심 좌표(x_o, y_o)는 인터파크 좌석 배치도에서 무대 중앙 위치 기준으로 (100.494, 24.452)으로 설정하였다.

무대 중앙과의 직선거리(stage_distance)는 좌석과 무대 중심 간의 유클리드(Euclidean) 거리를 계산한다. 이 값이 작을수록 무대와 가까운 좌석임을 의미한다.

$$stage_distance = \sqrt{(x - x_o)^2 + (y - y_o)^2}$$

공연장 중앙선과의 거리 (center_distance)는 공연장 중앙축 (무대 중앙을 지나는 세로축)으로부터 좌석이 얼마나 벗어나 있는지를 계산한다. 값이 작을수록 중앙 좌석에 가깝고, 값이 클수록 사이드 좌석임을 의미한다.

$$center_distance = |x - x_o|$$

무대 중심과 좌석 간의 관람 각도 (viewing_angle)는 관객이 무대를 바라보는 상대적인 각도를 계산한다. 중앙에 가까운 좌석은 각도가 작고, 좌우 측면으로 갈수록 각도가 커진다. 이를 통해 사이드 좌석에서 발생하는 시야 왜곡 효과를 모델이 학습할 수 있도록 하였다. 관람 각도는 좌석과 무대 중심의 상대 위치를 기반으로 계산하였으며, 각도의 방향성과 사분면 정보를 정확히 반영하기 위해 atan2() 함수를 사용하였다.


$$viewing_angle = \tan^{-1}\left(\frac{y - y_o}{|x - x_o|}\right)$$

이를 통해 생성된 공간 정보 피쳐 stage_distance, center_distance, viewing_angle은 좌석 판매 여부 예측 모델의 입력 변수로 활용되며, 이후 가격 세분화 정책 수립 과정에서도 좌석의 실제 관람 가치를 반영하는 핵심 변수로 사용된다.

3.2. 분석용 데이터 프레임 생성

우리의 목표는 공연 직전일 기준 좌석의 판매 여부를 예측하는 것이다. 공연일 바로 전날의 판매여부 데이터를 사용하기 위해 days_to_show, 즉 공연일까지 남은 일수를 나타내는 변수값이 1인 행만을 필터링한다. 5/3 19:00 회차는 공연 직전일 수집 데이터가 없기 때문에 분석 대상에서 제외하였고 최종 분석 대상은 5/5 19:00 회차부터 5/24 19:00 회차까지, 총 25개 회차이다. 각 회차 당 947석이 존재하기 때문에 최종 데이터프레임은 23,675행이 존재한다.

모델의 타깃 변수는 is_sold, 즉, 판매여부이다. 판매된 좌석은 1, 미판매 좌석은 0값을 가진다. 최종 예측 모델에 사용한 인풋 변수는 총 35개이다. 각 변수에 대한 정의 및 변수 유형은 부록의 [표 A-1]에 정리하였다.



[그림 8] is_sold 변수 값 분포

분류	변수명
좌석 위치	x, y, floor_no, zone, row_no, seat_no
좌석 등급, 가격	class, price
좌석 리뷰	rating_count, avg_rating, visibility_kw_rating, seat_kw_rating, lighting_kw_rating, sound_kw_rating
회차 정보	calendar_target_date, time_text, day_of_week, is_weekend
캐스팅 정보	렘피카, 라파엘라, 마리네티, 타데우스, 수지, 남작부인, 남작
배우 별 인스타 팔로워 수	insta_렘피카, insta_라파엘라, insta_마리네티, insta_타데우스, insta_수지, insta_남작부인, insta_남작
무대 시야 정보	stage_distance, center_distance, viewing_angle

[표 4] 전체 인풋 변수 분류 별 정리

범주형 변수들은 one-hot encoding을 적용하였다. 수치형 변수들은 StandardScaler로 정규화하였고, 결측치는 0으로 대체하였다.

3.3. 모델링

본 연구의 목표는 개별 좌석의 판매 여부 (is_sold)를 예측하는 것으로, 이를 이진 분류 문제로 정의하였다. 예측 모델은 공연 시작 전 시점에서 각 좌석이 판매될 확률을 추정하며, 이를 기반으로 좌석 수요 분석 및 가격 정책 시뮬레이션에 활용하였다.

모델링에는 Logistic Regression, Balanced Logistic Regression, Random Forest, XGBoost, HistGradient Boosting, LightGBM, CatBoost의 총 7개의 분류 모델을 사용하였다. 데이터 분할은 정보 누수를 방지하고 실제 운영 환경을 반영하기 위해 좌석 단위가 아닌 회차 단위로 수행하였다. 전체 25개 회차 중 20개 회차를 학습 데이터로, 5개 회차를 테스트 데이터로 사용하였다. 테스트 데이터는 5월 6일 19:30, 5월 14일 19:30, 5월 17일 19:00, 5월 20일 14:30, 5월 24일 19:00 회차로 구성하였다.

3.3.1. 모델 성능 비교

먼저 각 모델의 기본 하이퍼파라미터를 사용하여 성능을 비교하였다. 학습 데이터와 테스트 데이터는 회차 단위 랜덤 스플릿을 기준으로 구성하였으며, 이를 통해 최종 모델 후보군을 선정하였다. 모델 평가는 Accuracy, F1 Score, ROC-AUC 등 분류 성능 지표를 중심으로 수행하였다.

후보 모델의 성능 향상과 과적합 완화를 위해 Optuna 기반 하이퍼파라미터 최적화를 수행하였다. 학습 데이터는 다시 Train:Validation:Test = 16:4:5의 비율로 분할하였으며, Validation 데이터셋의 F1 Score를 목적함수로 설정하였다. 각 모델에 대해 총 40회의 Trial을 수행하여 최적의 하이퍼파라미터 조합을 탐색하였다. 이를 통해 모델별 일반화 성능을 비교하고 최종 모델 선정에 활용하였다.

3.3.2. 최종 모델 선정 및 추가 최적화

3.3.1.에서의 실험 결과 CatBoost가 가장 우수한 성능을 보였으며, 이를 최종 모델로 선정하였다. 최종 모델의 성능을 더욱 향상시키기 위해 Optuna 탐색 횟수를 120회로 확대하여 추가 하이퍼파라미터 최적화를 수행하였다.

본 연구의 예측 결과는 단순 성능 비교를 넘어 이후 가격 정책 시뮬레이션에 직접 활용되므로, Accuracy만을 기준으로 모델을 평가하는 것은 적절하지 않다. 따라서 Accuracy, F1 Score, ROC-AUC뿐만 아니라 Confusion Matrix를 함께 분석하여 판매 좌석과 미판매 좌석을 얼마나 정확하게 구분하는지 검토하였다. 특히 실제로 판매되지 않은 좌석을 판매될 것으로 예측하는 경우는 가격 정책 수립 과정에서 과도한 가격 인상으로 이어질 수 있으므로, 해당 오류에 대해 보다 엄격하게 평가하였다.

3.3.3. 확률 예측 품질 평가

본 연구에서는 좌석 판매 여부뿐 아니라 좌석별 판매 확률 자체를 정책 시뮬레이션에 활용하므로, 예측 확률의 신뢰도를 검증할 필요가 있었다. 일반적으로 분류 모델이 출력하는

확률은 실제 발생 확률과 차이가 있을 수 있으며, 이러한 차이를 분석하는 과정을 Calibration 평가라고 한다.

본 연구에서는 모델이 출력하는 확률의 품질을 검사하기 위해 최종 CatBoost 모델에 대해 Reliability Diagram, Brier Score, Expected Calibration Error (ECE), Negative Log-Likelihood (NLL)를 관찰하였다. 이를 통해 모델이 출력한 판매 확률이 실제 판매 확률을 얼마나 정확하게 반영하는지 평가하였다.

3.4. 정책 시뮬레이션 설계

본 연구에서는 예측된 좌석별 판매 확률을 활용하여 데이터 기반 가격 정책을 설계하고, 기존 고정 가격 정책과의 성과를 비교하였다. 이를 위해 모델 학습에 사용한 25개 회차 각각에 대해 독립적인 가격 정책 시나리오를 최적화를 통해 생성하였다. 가격 탐색 범위는 1만 원에서 20만 원까지로 설정하였으며, 실제 공연 산업의 가격 체계와 소비자의 가격 인지 특성을 고려하여 1만 원 단위로 가격을 부여하였다.

가격 결정은 좌석별 기대수익을 최대화하는 방식으로 수행하였다. 기대수익은 좌석 가격과 해당 가격에서의 예측 판매 확률의 곱으로 정의되며, 각 좌석은 기대수익이 가장 크게 되는 가격을 선택하도록 하였다. 이를 위해 모델 학습에 사용된 가격 변수(price)에 다양한 가격 후보를 입력하여 판매 확률을 재예측하고, 각 가격별 기대수익을 계산하였다.

$$p_i^* = \arg \max_{p \in \Omega} [p \cdot P(Y_i = 1 | X_i, p)]$$

기호	정의
p_i^*	좌석 i 의 최적 가격
X_i	좌석 i 의 특징 벡터
Y_i	판매 확률
Ω	탐색 가격 집합. $\Omega = \{10,000, 20,000, \dots, 200,000\}$

[표 5] 최적화 목적함수의 기호 정의

가격 최적화는 Greedy + Cap 방식을 적용하였다. 좌석을 무대와 가까운 순으로 정렬한 후 순차적으로 가격을 결정하였으며, 현실적인 가격 체계를 유지하기 위해 뒷좌석의 가격이 앞좌석의 가격을 초과할 수 없도록 가격 상한 제약을 적용하였다.

이후 공연 운영 관점의 제약을 반영하기 위한 후처리를 수행하였다. 구체적으로 최소 4개 이상의 가격 등급이 존재하도록 하였으며, 동일 가격이 연속되는 구간은 최대 5열로 제한하였다. 이를 통해 지나치게 단순하거나 비현실적인 가격 구조가 생성되는 것을 방지하였다.

최종적으로 제안된 가격 정책에 대해 좌석 점유율과 기대 매출을 핵심 성과 지표(KPI)로 산출하였으며, 이를 기존 가격 정책과 비교하여 정책 효과를 평가하였다.

4. 결과

4.1. 최종 모델 선정 및 모델 관찰

4.1.1. 최종 모델 선정

7개의 모델에 대해 기본 파라미터로 학습 성능을 비교한 후 Optuna 기법을 활용하여 하이퍼파라미터 튜닝을 진행하였다.

모델	Accuracy		Precision		Recall		F1-score		ROC-AUC	
	Train	Test	Train	Test	Train	Test	Train	Test	Train	Test
CatBoost	0.9402	0.7852	0.9616	0.9276	0.9291	0.7726	0.9451	0.8430	0.9861	0.8728
XGBoost	0.8800	0.7692	0.9393	0.9463	0.8375	0.7324	0.8855	0.8257	0.9576	0.8721
HistGradientBoosting	0.8893	0.7725	0.9351	0.9402	0.8598	0.7426	0.8959	0.8298	0.9598	0.8619
LightGBM	0.9470	0.7457	0.9704	0.9129	0.9328	0.7290	0.9512	0.8106	0.9898	0.8263
Random Forest	0.8670	0.7487	0.9333	0.9460	0.8185	0.7035	0.8721	0.8069	0.9567	0.8367
Logistic Regression	0.7998	0.7578	0.8282	0.9663	0.8058	0.6781	0.8168	0.8069	0.8706	0.9105
Balanced LR	0.8103	0.7347	0.8676	0.9987	0.7761	0.6455	0.8193	0.7842	0.8711	0.9122

[표 6] 분류 모델 별 성능 비교 결과

관찰 결과 CatBoost는 테스트 데이터 기준 F1-score 0.8430으로 가장 높은 성능을 보였으며, ROC-AUC 또한 0.8728로 XGBoost(0.8721)와 유사한 수준의 우수한 분류 성능을 나타냈다. CatBoost는 학습 데이터에서 F1-score 0.9451, ROC-AUC 0.9861을 기록한 반면 테스트 데이터에서는 각각 0.8430, 0.8728을 기록하여 학습 성능과 테스트 성능 간의 차이가 확인되었다. 그러나 LightGBM과 비교할 때 테스트 데이터에서 더 높은 F1-score와 ROC-AUC를 기록하였다. 따라서 본 연구에서는 테스트 데이터 기준 가장 높은 F1-score와 상위권 ROC-AUC를 보인 CatBoost를 최종 모델로 선정하였다.

4.1.2. 추가 튜닝 및 모델 성능 관찰

최종 모델로 선정된 CatBoost에 대해 추가적인 성능 향상을 확인하기 위하여 Optuna 기반 하이퍼파라미터 최적화를 수행하였다. 탐색 횟수는 120 Trials로 설정하였으며, 최종적으로 도출된 하이퍼파라미터는 [표 7]과 같다.

파라미터	값
iterations	1040
depth	5
learning_rate	0.0456
l2_leaf_reg	18.87
random_strength	0.586
bagging_temperature	0.303


[표 7] Catboost 최종 하이퍼파라미터

추가 튜닝 결과, 테스트 데이터에서 Accuracy 0.7776, Precision 0.9276, Recall 0.7615, F1-score 0.8364, ROC-AUC 0.8728을 기록하였다. 특히 Precision이 0.9276으로 높게 나타나 모델이 판매될 것으로 예측한 좌석의 상당수가 실제 판매 좌석임을 확인할 수 있었다. 반면 Recall은 0.7615로 상대적으로 낮게 나타나 일부 판매 좌석을 미판매로 예측하는 사례가 존재하였다.

[그림 9]의 혼동행렬을 살펴보면 대부분의 판매 좌석을 정확하게 분류하였으며, 미판매 좌석에 대해서도 비교적 안정적인 예측 성능을 보였다. 일부 오분류 사례가 존재하여 실제 판매 여부를 완벽하게 구분하기에는 한계가 있었으나, 전반적으로 판매 좌석과 미판매 좌석을 효과적으로 구분하는 것으로 나타났다. 따라서 본 연구에서는 해당 모델을 좌석 수요 예측 및 가격 정책 시뮬레이션에 활용하기에 충분한 성능을 갖춘 것으로 판단하였다.

구분	Accuracy	Precision	Recall	F1	ROC-AUC
Train (20회차)	0.9345	0.9583	0.9220	0.9398	0.9846
Test (5회차)	0.7776	0.9276	0.7615	0.8364	0.8728

[표 8] Catboost 최종 성능




[그림 9] 최종 Catboost 모델의 혼동행렬

또한 최종 모델의 일반화 성능을 평가하기 위해 5-Fold Cross Validation을 수행하였다. 검증 결과 F1-score는 평균 $0.790(\pm 0.078)$, Accuracy는 평균 $0.785(\pm 0.047)$, Precision은 평균 $0.885(\pm 0.069)$, Recall은 평균 $0.720(\pm 0.108)$ 을 기록하였다. Fold별 성능 차이가 일부 관찰되었으나 전반적으로 유사한 수준의 성능을 유지하였으며, 특히 Precision의 변동 폭이 크지 않아 판매 가능성이 높은 좌석을 안정적으로 식별하는 경향을 확인할 수 있었다.

[그림 10]의 Fold별 혼동행렬에서도 대부분의 Fold에서 유사한 분류 패턴이 관찰되었으며, 특정 Fold에 과도하게 의존하지 않는 비교적 안정적인 예측 성능을 보였다. 이를 통해 최종 CatBoost 모델이 새로운 회차 데이터에 대해서도 일정 수준 이상의 일반화 성능을 확보하고 있음을 확인하였다.

Fold	F1 Score	Accuracy	Precision	Recall
1	0.814	0.776	0.822	0.807
2	0.828	0.841	0.890	0.773
3	0.873	0.826	0.998	0.776
4	0.667	0.744	0.877	0.538
5	0.766	0.738	0.839	0.705
평균 ± 표준편차	0.790 ± 0.078	0.785 ± 0.047	0.885 ± 0.069	0.720 ± 0.108

[표 9] 최종 Catboost 모델의 5-Fold Cross Validation 결과



[그림 10] 최종 Catboost 모델의 5-Fold Cross Validation 혼동행렬

최종 모델의 Feature Importance를 분석한 결과, 무대와외 거리가 가장 중요한 변수로 나타났다. 또한 공연일, 열 번호, 중앙 거리 등 좌석 위치 및 공연 일정 관련 변수들이 높은 중요도를 보였으며, 캐스팅 정보와 SNS 언급량 관련 변수 역시 주요 변수로 확인되었다. 이는 좌석의 물리적 위치뿐만 아니라 공연 회차 특성과 출연진에 대한 관객 관심도 또한 좌석 판매에 영향을 미친다는 것을 의미한다. 따라서 본 연구에서 가정한 좌석 위치, 회차 정보, 캐스팅 등의 요인이 실제 판매 예측 과정에 유의미하게 반영되고 있음을 확인할 수 있었다.

순위	변수	Importance	비중(%)
1	stage_distance (무대 거리)	22.42	22.4
2	calendar_target_date (공연일)	8.53	8.5
3	row_no (열)	8.28	8.3
4	center_distance (중앙 거리)	8.24	8.2
5	y (좌표)	7.17	7.2
6	time_text (회차 시간)	6.46	6.5
7	라파엘라 (캐스팅)	4.79	4.8
8	렘피카 (캐스팅)	4.59	4.6
9	class (좌석 등급)	3.93	3.9
10	insta_렘피카	3.84	3.8
11	마리네티 (캐스팅)	2.89	2.9
12	day_of_week (요일)	2.67	2.7
13	seat_no (좌석번호)	1.98	2.0
14	insta_마리네티	1.93	1.9
15	price (가격)	1.69	1.7


[표 10] 최종 CatBoost 모델의 상위 15개 변수 중요도

4.2. 확률 예측 품질 평가

최종 모델에 대한 캘리브레이션 평가 결과를 관찰하였다. Reliability Diagram에서 예측 확률이 대각선(Perfect Calibration)에 가까울수록 모델이 출력한 확률이 실제 발생 확률과 유사함을 의미한다. 본 연구의 모델은 전반적으로 대각선과 유사한 형태를 보였으나, 대부분의 구간에서 곡선이 대각선 위에 위치하였다. 이는 동일한 예측 확률 구간에서 실제 판매 비율이 모델이 예측한 확률보다 다소 높게 나타났음을 의미하며, 모델이 판매 확률을 다소 보수적으로 추정하는 경향이 있음을 시사한다.

[표 11]은 최종 CatBoost 모델의 확률 예측 품질 평가 결과를 나타낸다. 테스트 데이터 기준 Brier Score는 0.153, ECE는 0.124, NLL은 0.455로 나타났다. ECE(Expected Calibration Error)는 예측 확률과 실제 발생 확률 간의 평균 차이를 의미하며, 본 연구의 모델은 평균적으로 약

12.4% 수준의 Calibration 오차를 보였다. 또한 Brier Score는 예측 확률과 실제 결과 간의 평균 제곱 오차를 측정하는 지표로, 0에 가까울수록 높은 확률 예측 정확도를 의미한다. NLL(Negative Log-Likelihood)은 모델이 실제 결과에 부여한 확률의 적합도를 평가하는 지표로, 값이 낮을수록 실제 관측 결과를 잘 설명하는 것으로 해석된다. 학습 데이터에 비해 테스트 데이터의 지표 값이 다소 높게 나타났으나, 이는 학습 과정에서 사용되지 않은 회차에 대한 일반화 오차가 반영된 결과로 해석할 수 있다. 종합적으로 볼 때 일부 Calibration 오차가 존재하지만, 모델이 출력한 판매 확률은 실제 판매 확률과 전반적으로 일관된 경향을 보였으며, 가격 정책 시뮬레이션에 활용하기에 충분한 수준의 신뢰성을 확보한 것으로 판단하였다.



[그림 11] 최종 Catboost 모델에 대한 Reliability Diagram

Split	Brier Score	ECE	NLL
Train	0.053	0.062	0.190
Test	0.153	0.124	0.455

[표 11] 최종 CatBoost 모델의 확률 예측 품질 평가 결과


4.3. 정책 시뮬레이션 결과

4.3.1. 회차별 가격 세분화 결과

본 연구에서는 예측된 좌석별 판매 확률을 활용하여 회차별 가격 최적화를 수행하였으며, 그 결과를 웹 기반 시각화 페이지로 구현하였다 (<https://jiyoung0128.github.io/DS-capstone-visualization-page/>). 사용자는 각 회차에 대한 최적 가격 정책과 좌석별 가격 분포를 확인할 수 있으며, 기존 가격 체계와의 차이를 직관적으로 비교할 수 있다.

[그림 12]는 2025년 5월 15일 회차에 대한 가격 최적화 결과를 나타낸다. 기존 공연장의 가격 정책은 좌석을 4개 등급으로 구분하여 동일 등급 내 모든 좌석에 동일한 가격을 부여하는 구조를 사용하였다. 반면 본 연구에서 제안한 정책은 좌석별 수요 차이를 반영하여 가격을 결정하므로 회차에 따라 7~8개의 가격 등급이 형성되었다.

특히 기존 정책에서는 가격 경계가 구역 단위로 명확하게 구분되는 반면, 제안한 정책에서는 무대와와의 거리 및 좌석 수요를 반영하여 보다 연속적이고 세분화된 가격 분포가 나타났다. 이를 통해 동일 등급 내에서도 수요 수준이 다른 좌석에 차별화된 가격을 적용할 수 있음을 확인하였다.



[그림 12] 5월 15일 19:30 회차 기존 가격과 제안 가격 정책 시나리오 비교

4.3.2. 회차별 KPI 비교

[그림 13]의 예시 회차를 대상으로 정책 효과를 비교한 결과, 제안한 가격 정책은 기존 정책 대비 좌석 점유율과 기대 매출이 모두 증가하는 것으로 나타났다. 이는 좌석별 수요 특성을 반영한 가격 조정이 관객의 구매 의사와 보다 잘 부합하였기 때문으로 해석할 수 있다.

또한 판매 확률 변화와 실제 판매 결과를 비교한 시각화 결과에서도 제안한 정책이 좌석별 수요 수준을 보다 효과적으로 반영하고 있음을 확인할 수 있었다. 다만 최적화는 회차별 수요 구조에 따라 수행되므로, 일부 회차에서는 매출 증가 대신 점유율 증가가 나타나는 사례도 관찰되었다.

지표	기존 (관측가)	제안 (최적)	기존 대비 증감
판매 좌석 수	486	629	+143
좌석 점유율	51.87%	67.13%	15.26%p
매출 (prob≥0.5)	68,570,000원	74,290,000원	+8.34%

[그림 13] 5월 15일 19:30 회차의 KPI 비교 결과

4.3.3. 전체 회차 성과 비교

[표 12]는 전체 25개 회차에 대해 기존 가격 정책과 제안한 가격 정책의 성과를 비교한 결과를 나타낸다. 제안한 정책 적용 시 평균 점유율은 58.82%에서 70.57%로 11.75%p 증가하였으며, 총 매출은 188,007만 원에서 195,905만 원으로 약 4.20%(7,898만 원) 증가하였다.

이는 좌석별 판매 확률을 기반으로 가격을 세분화할 경우, 기존의 획일적인 4등급 가격 체계보다 더 높은 수준의 수요 대응이 가능함을 의미한다. 특히 점유율과 매출이 동시에 증가한 결과는 제안한 가격 정책이 공연장의 수익성과 좌석 활용도를 함께 개선할 수 있음을 보여준다. 따라서 본 연구에서 제안한 데이터 기반 가격 세분화 정책은 공연 산업의 가격 의사결정을 지원하는 실질적인 활용 가능성을 갖는 것으로 판단된다.

지표	기존(실제)	제안	변화
평균 점유율	58.82%	70.57%	+11.75%p
총 매출	188,007만 원	195,905만 원	+4.20%(+7,898만 원)

[표 12] 전체 25개 회차에 대한 정책 시뮬레이션 성과 비교

5. 결론

5.1. 결론 및 제언

본 연구는 공연 좌석 판매 데이터를 활용하여 좌석 단위의 판매 여부를 예측하고, 이를 기반으로 데이터 기반 가격 세분화 정책을 제안하는 것을 목적으로 수행되었다. 이를 위해 좌석 위치 정보뿐만 아니라 공연 일정, 캐스팅 정보, 좌석 리뷰 기반 특징 등을 통합하여 좌석별 판매 여부를 예측하는 머신러닝 모델을 구축하였다.

모델링 결과, CatBoost가 최종 모델로 선정되었으며 테스트 데이터 기준 F1-score 0.8364와 ROC-AUC 0.8728을 기록하였다. 또한 ECE(Expected Calibration Error)는 0.124로 나타나 예측 확률과 실제 판매 확률 간의 차이가 평균적으로 약 12.4% 수준임을 확인하였다. 이를 통해 본 연구의 모델은 판매 여부를 예측하는 동시에 판매 확률 자체도 정책 시뮬레이션에 활용 가능한 수준의 신뢰성을 확보한 것으로 판단하였다.

예측된 판매 확률을 활용하여 회차별 가격 최적화를 수행한 결과, 기존의 4등급 고정 가격 정책보다 세분화된 7~8개 수준의 가격 체계를 도출할 수 있었다. 정책 시뮬레이션 결과, 전체 25개 회차 기준 평균 좌석 점유율은 58.82%에서 70.57%로 증가하였으며, 총 매출 또한 188,007만 원에서 195,905만 원으로 증가하였다. 이는 좌석별 수요 특성을 반영한 데이터 기반 가격 정책이 공연장의 수익성과 좌석 활용도를 동시에 개선할 가능성이 있음을 보여준다.

특히 본 연구는 공연 시작 전 확보 가능한 정보만을 활용하여 좌석 단위의 최종 판매 여부를 예측할 수 있음을 확인하였다는 점에서 의의가 있다. 이는 공연이 진행되기 이전 단계에서도 좌석 수요를 예측하고 가격 정책을 설계할 수 있음을 의미한다. 또한 예측된 판매 확률을 활용한 가격 세분화 정책 시뮬레이션을 통해 기존 고정 가격 정책 대비 좌석 점유율과 매출의 개선 가능성을 확인하였다. 따라서 본 연구는 공연 산업에서 좌석 단위 수요 예측과 데이터 기반 동적 가격 정책의 활용 가능성을 실증적으로 제시하였으며, 향후 실제 공연장의 가격 의사결정 및 수익 관리 체계 구축에 기여할 수 있을 것으로 기대된다.

5.2. 프로젝트의 한계 및 향후 과제

본 연구는 공연 산업에서의 데이터 기반 가격 정책 가능성을 확인하였으나, 몇 가지 한계를 가진다.

첫째, 데이터의 한계가 존재한다. 본 연구에서는 좌석 판매 여부를 기준으로 분석을 수행하였으나, 실제 판매 과정에서 적용된 각종 할인 정책, 이벤트 프로모션, 카드사 제휴

할인 등의 정보는 확보하지 못하였다. 따라서 실제 관객이 지불한 가격과 차이가 존재할 수 있으며, 향후 연구에서는 보다 정교한 매출 데이터를 활용할 필요가 있다. 또한 분석에 사용된 공연 회차가 25개로 제한되어 있어 다양한 수요 패턴을 충분히 반영하지 못했을 가능성이 있다.

둘째, 가격 탐색 범위의 한계가 존재한다. 본 연구의 가격 최적화는 실제 운영되지 않았던 가격 수준까지 포함하여 탐색을 수행하였다. 따라서 시뮬레이션에서 도출된 일부 가격은 실제 시장 환경에서 관객이 수용할 수 있는 수준과 차이가 있을 수 있다. 향후 연구에서는 과거 가격 정책과 소비자 반응 데이터를 함께 활용하여 보다 현실적인 가격 탐색 범위를 설정할 필요가 있다.

셋째, 정책 시뮬레이션 과정에서 좌석 간 수요 이동 효과(Cannibalization)를 고려하지 못하였다. 실제 공연 예매에서는 특정 좌석의 가격이 변할 경우 인접 좌석 또는 동일 구역 내 다른 좌석의 수요에도 영향을 미칠 수 있다. 그러나 본 연구에서는 각 좌석의 판매 확률을 독립적으로 가정하여 가격을 결정하였다. 향후 연구에서는 좌석 간 대체 관계와 수요 이동 효과를 반영한 최적화 모형을 구축함으로써 보다 현실적인 가격 정책을 설계할 수 있을 것으로 기대된다.

마지막으로, 본 연구에서는 공연 시작 전 확보 가능한 정보만을 활용하여 판매 여부를 예측하였다. 향후에는 예매 진행률, 잔여 좌석 수, 예매 시점별 수요 변화 등 실시간 정보를 추가로 활용하여 보다 정교한 동적 가격 정책을 연구할 수 있을 것이다.

참고문헌

- [1] 김민선, 서준혁, 최승호 (2025). 머신러닝을 이용한 뮤지컬 잔여 좌석 예측 프레임워크를 통한 인자 분석. 디지털콘텐츠학회논문지, 26(3), 739-747.
- [2] 김은미, 남승진, 김태이, 홍태호 (2024). KoBERT와 KoGPT2 기반의 대형언어모델과 딥러닝을 통합한 리뷰 유용성 예측모형. 지능정보연구, 30(2), 195-209.
- [3] 예술경영지원센터·공연예술통합전산망(KOPIS) (2026). 2025년 공연시장 티켓판매 현황 분석 보고서. 예술경영지원센터.
- [4] 오제백 (2025). 뮤지컬 공연 초대 관객이 공연 흥행에 미치는 영향. 석사학위논문, 고려대학교 미디어대학원 뉴미디어학과.
- [5] 정혜정 (2023). 빅데이터를 활용한 국내 창작 뮤지컬 관람 리뷰 의미연결망 분석. 석사학위논문, 중앙대학교 대학원.
- [6] 주예린, 김정민, 박가연, 권영옥 (2023). 뮤지컬 공연의 예매 시점에 따른 가격과 수요 분석을 통한 동적 가격제의 필요성에 관한 연구. 상품학연구, 41(5), 15-23.
- [7] Gallego, G., & van Ryzin, G. (1994). Optimal dynamic pricing of inventories with stochastic demand over finite horizons. *Management Science*, 40(8), 999-1020.
- [8] Leslie, P. (2004). Price discrimination in Broadway theater. *RAND Journal of Economics*, 35(3), 520-541.
- [9] Phumchusri, N. (2013). Dynamic pricing in performance theater industry: An empirical study. In 2013 IEEE International Conference on Industrial Engineering and Engineering Management (IEEM) (pp. 1122-1126). IEEE.
- [10] Qiang, S., & Bayati, M. (2016). Dynamic pricing with demand covariates. arXiv:1604.07463. (SSRN No. 2765257)
- [11] Stavinova, E., Varshavskiy, I., Chunaev, P., Derevitskii, I., & Boukhanovsky, A. (2023). Dynamic pricing for the open online ticket system: A surrogate modeling approach. *Smart Cities*, 6(3), 63. <https://doi.org/10.3390/smartcities6030063>.

[12] Wadhwa, M., & Zhang, K. (2015). This number just feels right: The impact of roundedness of price numbers on product evaluations. *Journal of Consumer Research*, 41(5), 1172–1185.

[13] Zhu, F., Xiao, W., Yu, Y., Wang, Z., Chen, Z., Lu, A., Liu, Z., Wu, M., & Ni, S. (2022). Modeling price elasticity for occupancy prediction in hotel dynamic pricing. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM '22)* (pp. 4742–4746). ACM.

<https://doi.org/10.1145/3511808.3557646>.

부록

A. 전체 인풋변수

변수명	유형	예시 값	의미
class	str	VIP, OP, R, S, A	좌석 등급
x	float	50.215	좌석 x 좌표
y	float	146.372	좌석 y 좌표
floor_no	int	1, 2	층 정보
zone	str	A, B, C, OP	좌석 구역
row_no	int	4	열 번호
seat_no	int	1	좌석 번호
price	int	100000	티켓 가격
rating_count	int	3	좌석 리뷰 개수
avg_rating	float	4.625	좌석 평균 평점
visibility_kw_rating	float	-	시야 키워드 가중 평점
seat_kw_rating	float	-	좌석 상태 키워드 가중 평점
lighting_kw_rating	float	-	조명 키워드 가중 평점
sound_kw_rating	float	-	음향 키워드 가중 평점
calendar_target_date	date	2026-05-10	공연 날짜
time_text	str	2회 19:00	회차 시간
렘피카	str	정선아	배역 캐스팅 배우

라파엘라	str	차지연	배역 캐스팅 배우
마리네티	str	조형균	배역 캐스팅 배우
타데우스	str	김우형	배역 캐스팅 배우
수지	str	김혜미	배역 캐스팅 배우
남작부인	str	윤사봉	배역 캐스팅 배우
남작	str	김남수	배역 캐스팅 배우
day_of_week	str	월화수목금토일	요일
is_weekend	int	1 / 0	주말·공휴일 여부
stage_distance	int	-	좌석-무대 중심 거리
center_distance	int	-	공연장 중앙선과 거리
viewing_angle	int	-	시야 각도
insta_렘피카	int	-	배우 인스타 팔로워 수
insta_라파엘라	int	-	배우 인스타 팔로워 수
insta_마리네티	int	-	배우 인스타 팔로워 수
insta_타데우스	int	-	배우 인스타 팔로워 수
insta_수지	int	-	배우 인스타 팔로워 수
insta_남작부인	int	-	배우 인스타 팔로워 수
insta_남작	int	-	배우 인스타 팔로워 수

[표 A-1] 전체 인풋 변수 정리