

2026-01 딥러닝 텀프로젝트

개인 갤러리 Long-tail 검색을 위한 SigLIP2 기반 Adapter 임베딩 채널

팀원 : 2492003 공지율 2392008 남재은 2392032 정지영

목차

1. 배경

2. 문제 정의 및 목표

3. 모델 및 데이터셋 소개

4. 실험1: Reranker

5. 실험1 결과 및 해석

7. 실험2: Adapter

8. 실험2 결과 및 검증


9. 결론 및 한계

Claim of Originality

본 프로젝트는
자체적으로 정의한 문제를 바탕으로
그에 맞는 데이터셋을 찾아 수행되었습니다.

배경

- 스마트폰 보급으로 개인이 보유한 사진 수가 크게 증가하면서 효율적인 이미지 검색의 중요성이 높아지고 있다.
- 최근 CLIP과 같은 Vision-Language Model 기반 검색은 객체 중심 질의에서는 높은 성능을 보인다.
- 그러나 실제 사용자는 **"신나는 파티 사진"**, **"감성적인 밤 산책"**과 같은 질의를 자주 사용한다. 이러한 long-tail 질의는 객체 정보만으로 표현하기 어려워 기존 CLIP 기반 검색에서 성능이 제한된다.
- 본 연구는 이러한 문제를 해결하기 위한 첫 번째 단계로, SigLIP2 인코더를 고정(freeze)하고 그 위에 경량 어댑터를 학습해 이미지-텍스트 임베딩 공간을 재정렬한다. 다만 분위기·인물·날짜 같은 long-tail 쿼리에 대응하는 대규모 쿼리-정답 데이터셋은 존재하지 않으므로, 공개된 이미지-캡션 데이터셋(Flickr30k, COCO)을 proxy로 활용해 객체·장면 단위의 이미지-텍스트 정렬부터 개선한다.



문제 정의

문제

개인 갤러리 검색에서 사용자는 "클라이밍하는 나", "학회 뒷풀이", "감성적인 밤 산책" 같은 long-tail 쿼리를 입력하지만, 범용 VLM(SigLIP2)은 fine-grained한 이미지-텍스트 마진이 좁아 정답 이미지를 상위에 올리지 못하는 경우가 많다.

데이터 현실


이상적으로는 실제 개인 갤러리 쿼리-정답 쌍으로 학습해야 하지만, 그런 대규모 데이터셋은 공개된 것이 없고 직접 구축도 현실적으로 어렵다. 따라서 대규모 수집이 가능한 **이미지-캡션 쌍(Flickr30k, COCO)**을 쿼리-정답 쌍의 대리(proxy)로 사용해 객체·장면 중심 정렬부터 개선한다.

연구 질문

"Frozen SigLIP2 임베딩 위에 Residual MLP Adapter + Hard Negative Mining을 적용하면 fine-grained 이미지-텍스트 정렬을 정량적으로 개선할 수 있는가?"

연구 범위

- 본 연구의 어댑터는 객체·장면 중심 검색 성능 향상에 집중한다.
- 분위기·인물·날짜 등 실제 long-tail 쿼리 전반을 커버하려면 메타데이터·VLM 캡셔닝 등 추가 채널과의 결합이 필요하며, 이는 향후 과제로 남긴다.




목표

- 1 Frozen SigLIP2 위에 Residual MLP Adapter를 학습하여 fine-grained 이미지-텍스트 임베딩 공간 재정렬
- 2 Flickr30k 및 COCO 2017에서 Baseline 대비 Recall@K 정량 비교 (이미지-캡션 proxy 데이터를 활용한 객체·장면 중심 정렬 개선 검증)
- 3 Hard Negative Mining · 배치 크기 × Temperature 전략의 ablation을 통해 각 기법의 기여를 분리 측정
- 4 개인 갤러리(324장)에서 Baseline vs Adapter 검색 결과를 정성 비교하고, 실제 long-tail 쿼리에서의 한계를 확인
- 5 어댑터 없는 세팅에 Reranker를 추가 적용하여 상위 후보군 재정렬 효과 검증

SigLIP2 모델 소개

Model	SigLIP2-so400m-patch14-384
Input Size	384 × 384
Embedding Dim	1152
Similarity	Cosine Similarity
Encoder Training	Freeze
Role	Feature Extractor

- SigLIP2는 Google이 개발한 Vision-Language Model로, 이미지와 텍스트를 동일한 임베딩 공간에 매핑하여 검색 및 매칭 작업을 수행한다.
- 본 연구에서는 google/siglip2-so400m-patch14-384 모델을 사용하였으며, 이미지와 텍스트를 각각 1152차원 임베딩 벡터로 변환한 후 코사인 유사도로 유사도를 계산한다.
- SigLIP2 인코더는 고정(Freeze)된 상태로 사용하고, 생성된 임베딩만 어댑터의 입력으로 활용하였다. 이를 통해 소량 데이터 환경의 과적합과 Catastrophic Forgetting을 방지하고자 하였다.



데이터셋 소개

Dataset	학습 쌍 수	특징
Flickr30k	29,000	이미지당 캡션 1개 사용 / val 1,014 · test 1,000
COCO 2017 (all5)	591,435	이미지당 5개 캡션 전부 사용 (118,287 이미지)
합계	620,435	최종 모델 학습 설정

- Flickr30k와 COCO 2017은 이미지-텍스트가 함께 제공되는 대표적 데이터셋으로, SigLIP2로 임베딩을 사전 추출하여 어댑터 학습에 사용하였다.
- COCO는 이미지당 5개의 다양한 캡션을 보유하므로, 5캡션 전체(all5)를 사용해 같은 이미지에 대한 다양한 텍스트 표현을 학습하여 일반화를 향상시켰다.
- 단, Flickr30k·COCO의 캡션은 객체·동작 위주로 구성되어 있어, 분위기·특정 인물·배경 등 실제 long-tail 쿼리와는 분포 차이가 존재한다.



Flickr30k 예시 — "A little girl in a pink dress going into a wooden cabin." 등 이미지당 다중 캡션

실험1: Reranker

아이디어

Reranker를 적용하여 SigLIP2가 검색한 상위 후보군 내부의 순위를 재정렬해 보자.

Baseline 성능 확인

상위 후보 **10장** 중 정답 포함 확률 = **99.11%**

상위 후보 **5장** 중 정답 포함 확률 = **97.83%**

하지만 상위 후보 **1장**이 정답일 확률 = **88.66%**

문제 확인

정답 이미지가 상위 후보군 안에 있지만,
항상 1위인 것은 아님.

실험1: Reranker 원리

Top 5 · Top 10 · Top 50

순위 재정렬 대상 후보군 크기

Hard-case Oversampled

정답을 1위로 뽑은 easy case보다, 후보군엔 있으나 1위가 아닌 hard case를 **6배 가중**해 더 자주 학습.

Selective

정답을 확신하는 query엔 적용하지 않고, **top1 – top2 score $\leq$ threshold**인 불확실한 query에만 적용.

Residual Score

prediction = cosine similarity + **$\alpha \cdot \text{MLP_delta}$** ($\alpha \leq 0.1$ 보정 강도, MLP_delta = MLP 보정 점수)

실험1: Reranker 학습 설정

Dataset

Train · Validation : Flickr30k (7:2:1)
Test : Flickr30k, COCO

기대 효과

Reranker 적용 시 SigLIP2 Baseline 대비 **R@1** 향상.

MLP_delta score

Input (dim 2305): query emb · candidate img emb · cos sim
→ Linear (2305 → 512)
→ GELU → Dropout(0.2)
→ Linear (512 → 256)
→ GELU → Dropout(0.2)
→ Linear (256 → 1)
→ **Delta score**

확인할 수치

R@1

R@5

reranked_ratio : SigLIP2가 정답을 확신하지 못해 Re-ranker가 개입한 비율

실험1 결과

(1) Top50 : R@1 향상 실패

- SigLIP2가 정답을 확신하지 못하는 query가 거의 없어, Reranker의 개입이 무의미한 상태.
- Reranker 적용 시 SigLIP2가 이미 잘 정렬해 놓은 순위를 훼손함. **모든 검증 set에서 R@1 하락.**
- 상위 후보 50장은 후보군이 너무 넓어 hard negative sample로 쓰기에 부적합.

	dataset	model	R@1	R@10	R@50	reranked_ratio
0	Flickr30k Validation	SigLIP2 Baseline	0.886588	0.991124	0.998028	0.000000
1	Flickr30k Validation	SigLIP2 + Top-50 Hard-case Oversampled Selecti...	0.879684	0.973373	0.998028	0.053254
2	Flickr30k Test	SigLIP2 Baseline	0.878000	0.993000	0.998000	0.000000
3	Flickr30k Test	SigLIP2 + Top-50 Hard-case Oversampled Selecti...	0.862000	0.974000	0.998000	0.064000
4	COCO Test	SigLIP2 Baseline	0.494800	0.812800	0.951200	0.000000
5	COCO Test	SigLIP2 + Top-50 Hard-case Oversampled Selecti...	0.464400	0.740800	0.951200	0.269200

실험1 결과

(2) Top10 : 향상했으나 미미하여 실패

- 확신하지 못하는 query가 Flickr30k 약 **12%**, COCO 약 **44%**로 Reranker 개입이 유의미할 수 있는 상태.
- Reranker 적용 시 모든 검증 set에서 R@1 값 **약 1%** 상승.
- 상위 후보 10장은 hard negative sample로 쓰기에 적합.

	dataset	model	R@1	R@5	R@10	reranked_ratio
0	Flickr30k Validation	SigLIP2 Baseline	0.886588	0.978304	0.991124	0.000000
1	Flickr30k Validation	SigLIP2 + Top-10 Hard-case Oversampled Selecti...	0.901381	0.978304	0.991124	0.125247
2	Flickr30k Test	SigLIP2 Baseline	0.878000	0.981000	0.993000	0.000000
3	Flickr30k Test	SigLIP2 + Top-10 Hard-case Oversampled Selecti...	0.883000	0.981000	0.993000	0.118000
4	COCO Test	SigLIP2 Baseline	0.494800	0.732400	0.812800	0.000000
5	COCO Test	SigLIP2 + Top-10 Hard-case Oversampled Selecti...	0.505400	0.736600	0.812800	0.443800

실험1 결과

(3) Top5 : 향상했으나 미미하여 실패

- 확신하지 못하는 query가 Flickr30k 약 **50%**, COCO 약 **86%**로 Reranker 개입이 유의미한 상태.
- Reranker 적용 시 모든 검증 set에서 R@1 값 **약 1%** 상승.
- 상위 후보 5장은 hard negative sample로 쓰기에 적합.

	dataset	model	R@1	R@5	reranked_ratio
0	Flickr30k Validation	SigLIP2 Baseline	0.886588	0.978304	0.000000
1	Flickr30k Validation	SigLIP2 + Top-5 Hard-case Oversampled Selectiv...	0.897436	0.978304	0.489152
2	Flickr30k Test	SigLIP2 Baseline	0.878000	0.981000	0.000000
3	Flickr30k Test	SigLIP2 + Top-5 Hard-case Oversampled Selectiv...	0.881000	0.981000	0.478000
4	COCO Test	SigLIP2 Baseline	0.494800	0.732400	0.000000
5	COCO Test	SigLIP2 + Top-5 Hard-case Oversampled Selectiv...	0.503000	0.732400	0.860400

실험2 방법론 — 학습 구조

[Step 1] 임베딩 추출

이미지 / 캡션 → SigLIP2 (Freeze) → 이미지 / 텍스트 임베딩

[Step 2] 어댑터 학습

이미지 임베딩 → 어댑터 → 보정된 이미지 임베딩

[Step 2-5] Hard Negative Mining NEW

전체 학습셋(620K) 기준 각 이미지와 코사인 유사도가 가장 높은 텍스트 **K=10**개를 hard negative로 선택 · 정답 쌍은 마스킹 후 제외 · 5 epoch마다 어댑터 적용 임베딩으로 재마이닝(암묵적 커리큘럼)

[Step 3] Hard Negative InfoNCE 손실

I→T : 분모 = in-batch B개 + hard negative 10개 → logits [B, B+K] · T→I : 기존 in-batch InfoNCE 유지 · $L = (L_{I2T} + L_{T2I}) / 2$

[Step 4] 어댑터 업데이트

계산된 Loss를 이용해 어댑터 가중치만 업데이트

실험2 결과 및 검증 — 성능 비교

1. Baseline vs Adapter (Flickr30k, Hard Negative K=10)

지표	Baseline	+ Adapter (HN K=10)	차이 (pp)
R@1	87.80%	89.30%	+1.50
R@5	98.10%	98.10%	0.00
R@10	99.30%	99.20%	-0.10

- 학습 : Flickr30k train 29,000 / 평가 : Flickr30k test 1,000 (1K gallery)
- Hard Negative K=10 적용 시 **R@1 +1.50pp 향상**
- Residual MLP Adapter (2.66M params), bs=512, $\tau=0.07$, 30 epochs, best epoch=11

실험2 결과 및 검증 — 성능 비교

2. Hard Negative Mining 효과 비교 (ResidualMLP, Flickr30k + COCO)

Hard Neg K	Best Ep	F R@1	ΔF	C5K R@1	$\Delta C5K$
0 (없음)	7	88.10%	+0.30	50.90%	+1.42
10	11	89.30%	+1.50	51.38%	+1.90

- Hard Negative K=10 : Flickr 개선폭 **5배** (0.30 → 1.50)
- Best Epoch이 7→11로 늦춰짐 — 더 어려운 학습 신호로 더 오래 유효하게 학습
- C5K(COCO 5K gallery)에서도 일관되게 개선

실험2 결과 및 검증 – 성능 비교

3. 하이퍼파라미터 탐색 (배치 크기 × Temperature 전략)

실험	bs	τ	all5	Best Ep	F R@1	C5K R@1
Baseline	—	—	—	—	87.80%	49.48%
기준	512	0.07	✗	11	89.30%	51.38%
bs=2048, τ =0.05	2048	0.05	✗	23	89.30%	52.88%
bs=4096, τ =0.03	4096	0.03	✗	16	90.30%	54.60%
bs=4096, τ =0.03, all5	4096	0.03	✓	9	90.40%	54.64%
bs=8192, τ =0.02, all5 ★	8192	0.02	✓	8	91.00%	55.26%

- 배치 2배마다 τ 를 약 0.57배로 감소 → 결정 경계가 sharp해져 미세 구분 강제
- all5 추가로 C5K +0.04, C1K +1.10 추가 개선
- Best Epoch이 11→8로 감소 : 데이터 4배 증가로 빠른 수렴

실험2 결과 및 검증 — 성능 비교

4. Ablation : 어댑터 구조 비교 고정 조건 : HN K=10, bs=512, τ =0.07, epochs=30

어댑터	Params	Best Ep	F R@1	ΔF	C5K R@1	$\Delta C5K$
Baseline	—	—	87.80%	—	49.48%	—
SymmetricAdapter	2.66M	3	86.70%	-1.10	48.00%	-1.48
BottleneckMLP	0.30M	15	88.00%	+0.20	49.88%	+0.40
AttentionAdapter	5.32M	18	88.30%	+0.50	51.54%	+2.06
ResidualMLP	2.66M	11	89.30%	+1.50	51.38%	+1.90

- **ResidualMLP** : Flickr30k 1위. 단순 residual 구조가 가장 안정적
- **SymmetricAdapter** : 텍스트 임베딩까지 변환해 Frozen SigLIP2 정렬이 깨져 전 데이터셋 하락, Best Ep=3에서 이미 과적합
- **BottleneckMLP** : 경량(0.30M)이지만 COCO에서 선전
- **AttentionAdapter** : Best Ep=18로 가장 늦게 수렴

개인 갤러리 검색 데모 결과 (964장 갤러리, 7개 쿼리)

실험 설정

갤러리 : 개인 사진 964장 (여행·일상·음식 혼재)

모델 : ResidualMLP 최종 모델 (bs=8192, $\tau=0.02$, all5)

평가 지표 : R@1, R@5

성능 요약

R@1 4 / 7 57.1%

R@5 5 / 7 71.4%

#	쿼리	판정
1	groom walking on a path decorated with flowers under chandeliers	✓ R@1
2	holding two musical tickets in hand	✓ R@1
3	three bowls of ramen placed on a table	✓ R@1
4	freshly baked bread on a cooling rack	✓ R@1
5	food with white bread and corn dish together	⚠ R@5 (4위)
6	Singapore night view with Marina Bay Sands	✗ Miss
7	exterior of College of Computing and Data Science building	✗ Miss

↳ Miss 2건 모두 갤러리 내 유사 이미지가 다수 존재하는 케이스

분석 및 해석 — 어댑터가 작동하는 조건

벤치마크(COCO)와 실제 갤러리 테스트 모두에서 동일한 패턴 확인 : 시각적으로 독특한 장면 → **성공** / 갤러리 내 유사 이미지가 많을수록 → **실패**

성공 조건 — 시각적으로 구별되는 장면

- ▶ 갤러리 내 유일한 시각 패턴 보유
 - 결혼식 꽃장식 통로, 뮤지컬 티켓 두 장
 - 라멘 3그릇, 식빵 식힘망
- ▶ 쿼리가 구체적이고 서술적
 - 어댑터 학습 방식(긴 캡션 Flickr **18.1** words, COCO all5 다양성)과 잘 맞는 입력 형태
- ▶ 벤치마크에서도 동일 패턴 확인
 - COCO : 복잡한 상황 묘사 쿼리에서 개선 사례 **47건**
 - COCO 5K R@1 : 49.48 → 55.26 (**+5.78pp**)

실패 조건 — 갤러리 모호성·쿼리 불명확성

- ▶ 갤러리 내 유사 이미지가 다수 존재
 - 싱가포르 야경 : 야경 사진 다수 → 랜드마크 구별 불가
 - CCDS 건물 : 비슷한 대학 건물 사진이 상위 점령
 - COCO : 동일 카테고리 밀집 시 정답 마진 **0.025** (성공 **0.051**)
- ▶ 쿼리가 짧고 모호
 - "A bunch of items on a counter" 류 / 쿼리 길이 짧을수록 R@1 낮음
- ▶ 한계 및 해결 방향
 - 쿼리 구체화 ("Marina Bay Sands with lotus-shaped hotel at night")
 - 장기적 : 위치 메타데이터·VLM 자동 캡셔닝과 멀티채널 결합

결론 및 한계

성과 요약

- Frozen SigLIP2 위에 Residual MLP Adapter를 학습해 이미지-텍스트 임베딩 공간을 재정렬하였다.
- Flickr30k R@1 87.80% → 91.00% (+3.20pp) / COCO 5K R@1 49.48% → 55.26% (+5.78pp)** 달성
- Reranker는 Top-5·Top-10에서 소폭 향상이 관찰되었으나 전반적으로 Adapter 기반 retrieval을 크게 개선하지는 못하였다.

한계 — Proxy 데이터와 실제 Long-tail 쿼리의 간극

이미지-캡션 데이터(Flickr30k·COCO)를 proxy로 사용했기에, 학습된 어댑터는 **객체·장면 중심 쿼리**의 정렬 개선에 집중되어 있다. 사용자가 입력하는 특정 인물·분위기·날짜·행사(클라이밍·학회·여행) 쿼리는 캡션 데이터만으로 부족하며, 이에 대한 대규모 쿼리-정답 데이터셋은 공개된 것이 없어 본 연구 범위에서는 직접 다루지 못했다.

본 연구의 어댑터는 이 멀티 채널 시스템의 **객체·장면 정렬 채널**로서 기여하며, 이를 출발점으로 삼아 full long-tail 검색으로 확장할 수 있다.

핵심 기여

- Hard Negative Mining(K=10)** : K=0 대비 Flickr 개선폭 5배 (+0.30 → +1.50) — fine-grained 구분의 핵심
- 배치 크기 × Temperature 동반 감소** : 구조 변경 없이 C5K +5.78pp 달성 (구조 ablation 최고치 +2.06의 2.8배)
- COCO all5 학습** : 캡션 다양성 확보 → C1K 추가 +1.10pp

향후 과제 — 멀티 채널 검색 시스템

- VLM 자동 캡셔닝 채널** : 분위기·인물·배경 캡션 생성 후 텍스트 검색
- 메타데이터 채널** : 촬영 날짜·GPS·얼굴 클러스터 등 구조적 정보 활용
- 쿼리 라우팅** : 쿼리 유형(객체 vs 분위기 vs 인물)에 따라 적합한 채널로 자동 분기

참고문헌

- [1] SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding — <https://artgor.medium.com/paper-review-siglip-2-multilingual-vision-language-encoders-with-improved-semantic-understanding-b7b578002adc>
- [2] Flickr30k dataset — <https://huggingface.co/datasets/nlphuji/flickr30k>